Machine Learning Pipeline Report

Classificação de Síndromes Genéticas

Sérgio Barbosa

19 de abril de 2026

1 Metodologia

O pipeline foi estruturado em quatro fases principais, garantindo que o código pudesse ser executado como *scripts* autônomos e reprodutíveis:

- **Processamento de dados:** Os dados, inicialmente fornecidos em um arquivo *pickle* com uma estrutura hierárquica complexa (dicionários aninhados), foram achatados (*flattened*) para um formato tabular (matriz bidimensional). A integridade dos dados foi validada mediante a verificação de valores nulos e aplicou-se a normalização (*StandardScaler*) para garantir a estabilidade espacial dos vetores.
- **Análise de dados e Visualização:** A distribuição das síndromes foi analisada, confirmando um *dataset* perfeitamente balanceado. Aplicou-se o algoritmo t-SNE para reduzir os vetores de 320 dimensões para 2D, permitindo a validação visual da separabilidade das classes latentes.
- **Classificação:** Implementei o algoritmo *K-Nearest Neighbors* (KNN). Foram testados múltiplos valores de K (de 1 a 15) e duas métricas de distância (Euclidiana e Cosseno) com *10-fold cross-validation*, garantindo a robustez estatística dos resultados.
- **Métricas:** Implementou-se manualmente o cálculo de *Top-k Accuracy*, complementado pelas métricas de F1-Score (Macro) e AUC-ROC.

2 Resultados

A validação cruzada demonstrou que o modelo KNN otimizado com a métrica de **Distância de Cosseno ($K = 15$)** obteve o melhor desempenho na classificação dos *embeddings*, superando consistentemente a métrica Euclidiana ($K = 10$).

Tabela 1: Comparativo de Desempenho (10-Fold Cross-Validation)

Modelo	**F1-Score (Macro)**	**AUC (ROC)**
Euclidiana ($K = 10$)	0.7053	0.9446
Cosseno ($K = 15$)	**0.7642**	**0.9677**

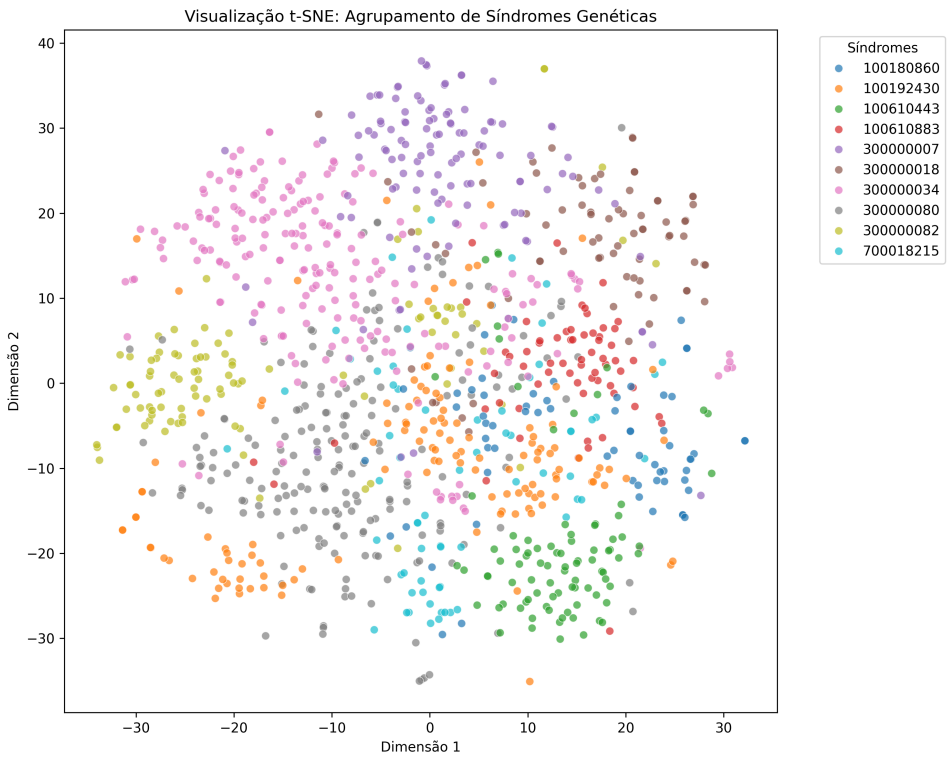

Figura 1: Visualização t-SNE dos *embeddings* agrupados por Síndrome.

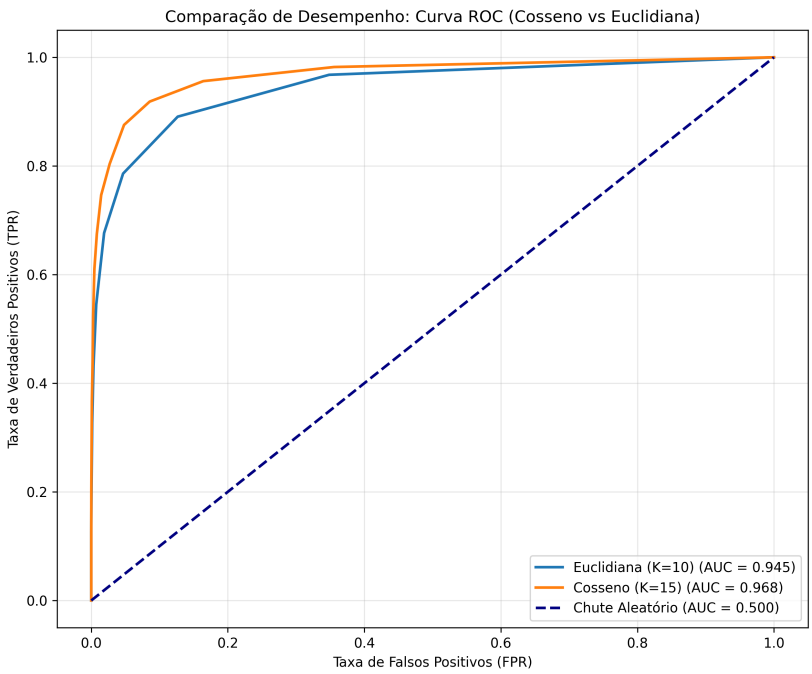

Figura 2: Curva ROC comparando o desempenho das distâncias de Cosseno e Euclidiana.

3 Análise e Conclusões

A superioridade da Distância de Cosseno em relação à Euclidiana evidencia a natureza dos dados fornecidos. Em espaços de alta dimensionalidade (vetores de 320 dimensões), os dados sofrem o fenômeno da *Maldição da Dimensionalidade*, onde as distâncias euclidianas relativas entre os pontos convergem, reduzindo a capacidade discriminativa do modelo.

A métrica de Cosseno superou esse obstáculo por mensurar o ângulo e a orientação direcional dos *embeddings*, capturando de forma mais precisa a similaridade semântica extraída pela rede neural original. Adicionalmente, a análise do gráfico t-SNE corrobora essa afirmação ao demonstrar a formação de *clusters* densos, justificando a eficácia do KNN (baseado em densidade e vizinhança) na tarefa de classificação.

4 Desafios e Soluções

O desafio técnico primordial consistiu na manipulação da arquitetura original dos dados. O *dataset* foi fornecido em um formato binário (*pickle*) estruturado por dicionários aninhados. Para mitigar o problema e otimizar o fluxo de dados, foi desenvolvido um algoritmo de iteração recursiva (*Data Flattening*) que extraiu de forma automatizada os metadados (Síndrome, Sujeito, Imagem) e as 320 dimensões do vetor correspondente, consolidando as informações em um *DataFrame* escalável para as bibliotecas do ecossistema *scikit-learn*.

5 Recomendações

Para iterações futuras no aprimoramento do classificador, recomenda-se:

1. Avaliar a implementação do algoritmo de redução de dimensionalidade **UMAP** (Uniform Manifold Approximation and Projection), que tende a preservar a topologia global de espaços complexos de maneira superior ao t-SNE.

2. Explorar arquiteturas mais robustas para dados tabulares densos, como *Multilayer Perceptrons* (MLP) ou algoritmos de *Ensemble* avançados (como *XGBoost* ou *LightGBM*), visando maximizar o F1-Score e mitigar erros em classes sobrepostas na fronteira de decisão.

6 Transparência e Uso de IA como Tutor Técnico

Em conformidade com as melhores práticas de transparência profissional, detalho abaixo como utilizei ferramentas de Inteligência Artificial Generativa durante este desafio técnico:

- **Aprendizado Ativo e Tutoria:** Como estudante do 1º período de Ciência da Computação e em fase de aprimoramento na linguagem Python, utilizei o modelo Gemini como um tutor técnico. A ferramenta me auxiliou na estruturação da sintaxe dos códigos e, principalmente, na explicação detalhada dos conceitos estatísticos (como t-SNE e KNN) e dos resultados gerados. Isso garantiu que eu compreendesse a fundo a lógica de cada etapa antes de aplicá-la.

- **Privacidade de Dados (Zero-Data Leak):** É fundamental ressaltar que **nenhum dado sensível do teste**, incluindo o *dataset* original (*pickle file*) ou os *embeddings* da Apollo Solutions, foi compartilhado ou enviado para a nuvem da IA. Todo o processamento de dados e treinamento dos modelos ocorreu de forma isolada no meu ambiente local.

- **Execução e Propriedade:** Toda a execução do *pipeline*, validação visual, organização do projeto e compilação deste relatório foram conduzidas por mim. O uso da IA foi estritamente focado em acelerar minha curva de aprendizado prático e garantir a qualidade da entrega.